

PROJETO ETD

Engenharia de Dados, ETL e Visualização Analítica

Economia e Conectividade Global

Análise da Relação entre PIB e Infraestrutura Digital à Escala Global

Trabalho realizado por: Inês Santos nº51563; Simão Abranches nº53682

Link para o GitHub: <https://github.com/SimaoAbranches/PFExtra-o>

Contexto

O presente relatório descreve o desenvolvimento completo do Projeto ETD, cujo objetivo central consiste na análise da relação entre o desenvolvimento económico, medido pelo Produto Interno Bruto (PIB), e a infraestrutura digital de cada país, nomeadamente a taxa de uso de Internet e as velocidades de ligação.

A escolha deste tema não é arbitrária. Num mundo crescentemente digital, o acesso à Internet deixou de ser um luxo para se tornar um fator estrutural de desenvolvimento: nações com melhor conectividade tendem a apresentar maior produtividade, acesso a mercados globais, literacia digital e capacidade de inovação. Compreender esta correlação a uma escala global permite identificar padrões, assimetrias e oportunidades que escapam à análise nacional isolada.

Pergunta Analítica Principal: Como é que o nível de desenvolvimento económico (PIB) de um país se correlaciona com a taxa de penetração e a velocidade da Internet, e que padrões emergem dessa relação à escala global entre 2000 e 2024?

Fonte de Dados

World Bank Indicators API (Fonte Principal)

A API do Banco Mundial disponibiliza séries temporais de indicadores macroeconómicos para todos os países membros, em formato JSON paginado. Foram recolhidos dois indicadores para 30 países, no período 2000-2024:

Indicador	Ficheiro Raw	Descrição
-----------	--------------	-----------

IT.NET.USER.ZS	internet_usage_all.json	% da população com acesso à Internet
NY.GDP.MKTP.CD	pib_all.json	PIB a preços correntes (USD)

A implementação usou paginação de 1000 registos por página com respeito ao *rate limit*. O campo “region” do ficheiro JSON foi usado para filtrar entidades do tipo “Aggregates” (regiões como “East Asia & Pacific”), garantindo que apenas países individuais entram no pipeline.

Licença: Creative Commons Attribution 4.0 (CC-BY 4.0): World Bank Dataset Terms of Use.

Wikipédia: Velocidades da Internet (Scraping)

Fonte complementar para enriquecer os dados do Banco Mundial com a velocidade média de download por país (Mbps), métrica ausente nas APIs governamentais. A página alvo é a lista global de países por velocidade de internet, mantida com base em dados Ookla/Speedtest Global Index.

A extração enfrentou o bloqueio HTTP 403, resolvido com injeção de “User-Agent” a simular um navegador Chrome real. A tabela HTML foi identificada pela classe “wikitable” e convertida com “pd.read_html()” via StringIO.

Cobertura Geográfica: 30 Países Alvo

Os países foram selecionados por código ISO3 para garantir correspondência exata com a API do Banco Mundial, cobrindo todas as regiões geográficas principais:

Região	Países	Região	Países
América	USA, CAN, MEX, BRA, ARG, CHL	Ásia e Pacífico	KOR, JPN, CHN, IND, SGP, IDN, AUS, NZL
Europa	GBR, FRA, DEU, ITA, ESP, PRT, NLD, CHE	África e Médio Oriente	SAU, ZAF, EGY, NGA, KEN, MAR, RUS, TUR

Arquitetura do Pipeline

O pipeline foi desenhado segundo uma arquitetura modelar com três camadas de dados e três scripts Python independentes, respeitando requisitos de separação clara entre Extract, Transform e Load:

Fase	Script	Camada de Dados	Responsabilidade
Extract	src/extract.py	data/raw/ (JSON + CSV)	API World Bank + Scraping Wikipédia
Transform	src/transform.py	data/staging/ (CSV intermédio)	Limpeza, DQ, join multi-fonte
Load	src/load.py	data/economia_internet.db	Star Schema SQLite + validação pós-load

A configuração centralizada usa um ficheiro .env com a variável API_URL, e o pipeline é executável sequencialmente em qualquer máquina local sem dependências de cloud.

Fase 1 – Extração (Extract)

- API World Bank: Decisões de Implementação

A função “extrair_indicador_banco_mundial()” constrói a URL com todos os 30 códigos ISO3 separados por ponto e vírgula, minimizando o número de chamadas à API. O *loop* de paginação usa os *metadados pages* retornados pela própria API para determinar o número total de páginas, evitando pedidos desnecessários.

```
url =  
f"{API_BASE}/country/{codigos}/indicator/{indicador}?format=json&per_page  
=1000&date=2000:2024"
```

Os dados são guardados em ficheiro JSON com estrutura [metadata, registos], preservando o formato original da API na camada raw, decisão que garante reprodutibilidade: qualquer etapa posterior pode reprocessar os dados brutos sem nova chamada à rede.

- Scraping Wikipédia: Correção Técnica

A extração da Wikipédia exigiu duas correções à implementação inicial:

- Injeção de “User-Agent HTTP” para contornar bloqueio 403 (o servidor bloqueia pedidos sem identificação de browser);

- Uso de “StringIO” para envolver o HTML antes de passar ao “pd.read_html()” (corrige FutureWarning/erro em pandas ≥ 2.0 que descontinuou a passagem de string HTML direta).

```
| html_stream = StringIO(str(tabela)) df = pd.read_html(html_stream)[0]
```

Fase 2 – Transformação e Qualidade de Dados

- Fluxo de Transformação

O script “transform.py” executa seis passos sequenciais documentados com *logging* numerado:

Passo	Nome	Operação
1	Carregar dados brutos	JSON do Banco Mundial + CSV da Wikipédia
2	Processar Banco Mundial	Filtrar agregados, alinhar tipos, “UPPER()” nos nomes
3	Inner Join BM Internet e PIB	Join por (country_name, year), preserva só registos com ambos os indicadores
4	Preparar Wikipédia	Normalizar colunas, aplicar mapeamento de nomes
5	Left Join BM com Wikipédia	Join por “country_name” mapeado, preserva histórico, nulos aceites
6	Guardar staging	CSV: fact_economy_internet_staging.csv

- Regras de Qualidade dos Dados

As regras foram definidas antes da implementação e aplicadas pela função “aplicar_regras_qualidade()”:

#	Regra	Decisão	Justificação
R1	Indicadores essenciais nulos	Remover registo	Registo sem valor não contribui para análise

R2	internet_usage_pct fora de [0, 100]	Forçar intervalo	Percentagem fora do domínio válido indica erro de fonte
R3	gdp_usd ≤ 0	Remover registo	PIB negativo ou nulo é economicamente incoerente
R4	Duplicados (país, ano)	drop_duplicates()	Garante unicidade da chave primária no Star Schema
R5	Agregados regionais no BM	Filtrar por "region.value"	"East Asia & Pacific" não é país, excluído por região = Aggregates

- Estratégia de Matching Multi-Fonte

O cruzamento entre o Banco Mundial e a Wikipédia exigiu um mapeamento explícito de nomenclatura, dado que as duas fontes usam convenções distintas. O dicionário "MAPA_NOMES_WIKI_PARA_BANCO_MUNDIAL" resolve as divergências mais comuns:

Nome Wikipedia	Nome Banco Mundial	Razão da Divergência
Russia	Russian Federation	Nome formal vs. nome comum
South Korea	Korea, Rep.	Nome coloquial vs. abreviatura oficial
Turkey	Turkiye	O BM atualizou o nome em 2022
Egypt	Egypt, Arab Rep.	Nome formal da república

- Decisão de Join:

Inner Join entre Internet e PIB (garante que só entram registos com ambos os indicadores), e Left Join com Wikipédia (preserva o histórico económico completo, aceitando os nulos de velocidade para países sem dados de scraping).

- Camada Staging: Dados Produzidos

O ficheiro `fact_economy_internet_staging.csv` constitui a camada intermédia do pipeline. A amostra dos dados confirma a estrutura esperada e a qualidade das transformações aplicadas.

30	25	7	+/- 650
Países	Anos	Colunas	Linhas
<i>cobertura global</i>	<i>2000 – 2024</i>	<i>por registo</i>	<i>estimativa (país × ano)</i>

- Esquema do Ficheiro Staging

Campo	Tipo	Origem	Descrição
“country_code”	TEXT	Banco Mundial	Código ISO3 (ex: ARG, AUS, BRA)
“country_name”	TEXT	Banco Mundial	Nome do país (“Title Case” após <i>transform</i>)
“year”	INTEGER	Banco Mundial	Ano de referência (2000 a 2024)
“internet_usage_pct”	REAL	Banco Mundial	% da população com acesso à Internet
“gdp_usd”	REAL	Banco Mundial	PIB em USD correntes
“avg_connection_speed_mbit”	REAL	Wikipédia	Velocidade média de download (Mbps), valor único por país
“pipeline_processed_at”	TIMESTAMP	Pipeline	Data/hora de processamento (rastreadibilidade)

- Amostra Verificada dos Dados

A amostra fornecida do ficheiro *staging* confirma a correta execução do pipeline. Exemplos relevantes:

Código	País	Ano	Internet (%)	PIB (USD)	Velocidade (Mbps)
ARG	Argentina	2000	7,04%	284,2B	111,54
ARG	Argentina	2020	85,51%	385,7B	111,54
ARG	Argentina	2024	89,67%	638,4B	111,54
AUS	Austrália	2000	46,76%	416,9B	154,09
AUS	Austrália	2010	76,00%	1,15T	154,09

Nota sobre a velocidade de Internet: O valor de “avg_connection_speed_mbit” é idêntico para todos os anos do mesmo país (ex: Argentina = 111,54 Mbps em todos os anos). Isto reflete uma limitação conhecida da fonte Wikipédia, que não disponibiliza série temporal, apenas um valor atual. Esta limitação está documentada no relatório de qualidade e foi aceite como *trade-off* do *Left Join*.

Fase 3: Carregamento e Modelação (Load)

- Escolha do Motor de Armazenamento

Foi escolhido o SQLite. A decisão justifica-se por três razões:

- Portabilidade: o ficheiro .db é autocontido, sem servidor, executável em qualquer computador;
- Simplicidade operacional: sem necessidade de configuração, ideal para o âmbito académico do projeto;
- Compatibilidade: SQLite é suportado nativamente pelo Power BI Desktop como fonte de dados local.

Para um ambiente de produção com múltiplos utilizadores ou volumes maiores, a migração para o “PostgreSQL” seria direta, dado que o Star Schema implementado é compatível com ambos.

- Modelo de Dados: Star Schema

O modelo dimensional implementado segue a estrutura clássica do Star Schema, com duas tabelas de dimensão e uma tabela de factos central:

Tabela	Campo	Tipo/Chave	Descrição
"dim_countries"	country_code	TEXT · PK	Código ISO3 do país
	country_name	TEXT	Nome do país
	wiki_country	TEXT	Nome original da Wikipédia
"dim_time"	year	INTEGER · PK	Ano de referência
"fct_economy_internet"	country_code	TEXT · FK → dim_countries	Chave estrangeira do país
	year	INTEGER · FK → dim_time	Chave estrangeira do tempo
	internet_usage_pct	REAL	% população com Internet
	gdp_usd	REAL	PIB em USD
	internet_speed_mbits	REAL	Velocidade média (Mbps)
	pipeline_processed_at	TEXT	Timestamp de processamento

```
PRIMARY KEY (country_code, year) -- chave composta na tabela de factos
FOREIGN KEY (country_code) REFERENCES dim_countries(country_code) FOREIGN
KEY (year) REFERENCES dim_time(year) PRAGMA foreign_keys = ON;
```

- Validação Pós-Load

O script "load.py" inclui uma função de auditoria automática executada após cada carga. Esta verificação compara o volume de registos no ficheiro CSV de *staging* com o total carregado na tabela de factos "SQLite":


```
cursor.execute("SELECT COUNT(*) FROM fct_economy_internet") total_factos
= cursor.fetchone()[0] if total_factos == total_staging:
print("SUCESSO: integridade volumétrica mantida a 100%")
```

Esta verificação automática deteta perdas silenciosas durante o processo de carga, uma causa frequente de discrepâncias difíceis de diagnosticar em pipelines sem esta salvaguarda.

Fase 4: Visualização (Power BI)

O *dashboard* final (ficheiro “PF_extração_final.pbix”) está organizado em duas páginas analíticas. A ligação ao SQLite garante que o Power BI atua exclusivamente como camada semântica e visual, não repete a extração nem a transformação.

- Página 1: “Panorama Global: Economia e Conectividade”

Elemento	Detalhe
Cartão: Velocidade Média	178,62 Mbps: média global dos 30 países
Cartão: Taxa de Acesso	56,36%: média global do uso de Internet
Mapa Mundial	Distribuição geográfica de velocidade e acesso por país
Scatter: PIB vs Acesso à Internet	Eixo X: PIB médio; Eixo Y: % Uso de Internet (evidencia a correlação central)
Filtros	Seleção de país (checkbox) e slider temporal 2000 a 2024

- Página 2: “Análise Detalhada: Rankings e Evolução Temporal”

Elemento	Detalhe
Ranking de Velocidade	Bar chart: Singapura lidera (cerca de 425 Mbps), seguida de França e do Chile
Ranking de Adoção	Bar chart: Países Baixos e Coreia do Sul no topo (cerca de 80%)

Evolução Temporal	Area chart 2000 a 2024: Uso de Internet (%) vs Velocidade (Mbps), crescimento acelerado pós-2010
Filtros	Consistentes com a Página 1 para exploração integrada

- Decisões de Design da Dashboard

- Normalização estética: avg_connection_speed_mbit- "Velocidade de Internet (Mbps)";
- Gráfico de dispersão PIB vs. Internet: visualização direta da hipótese analítica central, identificando clusters e outliers;
- Separação em duas páginas: macro (panorama global) e micro (rankings e evolução).

- Principais Insights Analíticos

178,6	56,4%	+80%	+/- 425
Mbps média global	Acesso médio global	Crescimento 2000 a 2024	Mbps Singapura
Velocidade download	Uso de Internet	Adoção de Internet	país mais rápido

Insight 1: Correlação Positiva PIB e Internet (com Outliers)

O gráfico de dispersão evidencia uma correlação positiva entre o PIB e o uso de Internet. Países com economias de maior dimensão tendem a apresentar maiores taxas de acesso. Contudo, a relação não é linear: identificam-se dois tipos de outliers relevantes:

- Países com PIB elevado, mas acesso abaixo do esperado (tipicamente estados com PIB concentrado em recursos e não em serviços digitais);
- Países com PIB mais modesto, mas conectividade acima da média (resultado de políticas públicas agressivas de infraestrutura de telecomunicações, ex: países do Sudeste Asiático).

Insight 2: A Velocidade não Segue o PIB

O ranking de velocidade de download revela que os países mais rápidos não são necessariamente os mais ricos. Singapura lidera com cerca de 425 Mbps, seguida de França (cerca de 350 Mbps) e Chile, este último com PIB per capita muito inferior aos

EUA ou Alemanha. Este padrão sugere que a velocidade de Internet é determinada principalmente por decisões de política de infraestrutura e pela densidade urbana, e não pelo PIB absoluto.

Insight 3: Aceleração Digital Pós-2010

A evolução temporal 2000 a 2024 mostra um crescimento consistente em ambas as métricas, com aceleração visível a partir de 2010, coincidindo com a expansão global do smartphone e do acesso móvel de banda larga. A velocidade média cresceu de forma mais acentuada do que a taxa de adoção nos últimos anos, refletindo modernização de redes em países já com altos níveis de uso (transição de ADSL para fibra e 5G).

Insight 4: Argentina como Caso de Estudo

Os dados da Argentina ilustram um padrão recorrente em economias emergentes: crescimento consistente do uso de Internet (de 7% em 2000 para quase 90% em 2024), mesmo durante períodos de contração severa do PIB (2001 a 2002, 2018 a 2020). Isto sugere que a adoção de Internet demonstra resiliência face a crises económicas, uma vez estabelecida a infraestrutura, a utilização mantém-se ou cresce mesmo com redução do rendimento disponível.

Instruções de Execução

- Requisitos:

- Python 3.9 ou superior;
- Dependências: `pip install -r requirements.txt`;
- Power BI Desktop (Windows) para visualização do dashboard;
- Ligação à Internet para extração via API e scraping.

- Configuração

Criar ficheiro “.env” na raiz do projeto:

```
| API_URL=https://api.worldbank.org/v2
```

- Execução Sequencial

1. `python src/extract.py` Extração: API World Bank + Scraping Wikipedia
2. `python src/transform.py` Transformação, DQ e *join multi-fonte*

Limitações e Trabalho Futuro

- Limitações Identificadas:

Limitação	Impacto e Mitigação
Velocidade sem série temporal	Wikipédia disponibiliza apenas valor atual, todos os anos do mesmo país têm a mesma velocidade. Aceitável como proxy, mas limita análise de evolução de velocidade.
30 países pré-selecionados	Cobertura não exaustiva. Alargável adicionando códigos ISO3 à lista "PAISES_ALVO_ISO3" no "extract.py".
SQLite sem concorrência	Limitação aceitável para uso local. Migração para PostgreSQL direta dado o Star Schema normalizado.
Power BI apenas Windows	Utilizadores macOS/Linux necessitam de Power BI Service ou alternativa (Metabase, Streamlit).
Scraping frágil	Alterações à estrutura HTML da Wikipédia podem quebrar a extração. Monitorização da estrutura wikitable necessária.

Conclusão

O Projeto ETD concretizou, de forma integral, os requisitos técnicos e analíticos definidos no enunciado: pipeline modular em três fases (Extract, Transform, Load), qualidade de dados explícita e documentada, modelação dimensional em Star Schema, e dashboard interativo com narrativa analítica clara.

A implementação demonstra preocupação real com rastreabilidade (dados raw preservados sem alteração), reprodutibilidade (execução sequencial documentada e dependências declaradas), integridade referencial (chaves primárias e estrangeiras no SQLite com PRAGMA foreign_keys = ON) e qualidade de dados (5 regras explícitas com logging e relatório gerado automaticamente).

Analiticamente, o projeto confirma a hipótese de partida: existe uma correlação positiva entre o desenvolvimento económico e a conectividade digital, mas esta relação não é linear nem determinista. Políticas públicas de telecomunicações, decisões de investimento em fibra ótica e densidade urbana podem colocar países de rendimento médio no topo dos rankings de velocidade, e a adoção de Internet demonstra resiliência

face a crises económicas, sugerindo que, uma vez estabelecida a infraestrutura digital, o acesso torna-se um bem quase essencial.